

持续同调（TDA）参考资料

主要内容与创新点整理

S RTP 项目组

2026 年 8 月

目录

1	Paper 1: Persistent Homology: A Pedagogical Introduction with Biological Applications	2
2	Paper 2: Topology-Informed Jet Tagging using Persistent Homology	2
3	Paper 3: Learning Significant Persistent Homology Features for 3D Shape Understanding	3
4	Paper 4: A Persistent Homology Design Space for 3D Point Cloud Deep Learning	4
5	Paper 5: Adaptive Topological Feature via Persistent Homology: Filtration Learning for Point Clouds	5
6	Paper 6: Topology and Data	6
7	Paper 7: Extracting Insights from the Shape of Complex Data Using Topology	7

1 Paper 1: Persistent Homology: A Pedagogical Introduction with Biological Applications

来源: arXiv:2505.06583v1 [math.AT], 2025年5月

作者: Aurelie Jodelle Kemme, Collins A. Agyingi (University of South Africa)

主要内容

本文是一篇面向初学者的持久同调 (Persistent Homology, PH) 教学论文, 系统性地介绍了从拓扑学基础到实际应用的全流程:

1. 数学预备知识: 拓扑空间、同胚、同伦、度量空间、点云表示;
2. 单纯复形与同调: 抽象单纯复形、链复形、边界映射、同调群、Betti 数;
3. 持久同调核心: 过滤 (filtration)、Čech 复形与 Vietoris-Rips 复形、条形码 (barcode) 与持久图 (persistence diagram);
4. 实际应用案例: 以 3-1 超螺旋 DNA 结构为对象, 从 PDB 坐标提取 $\rightarrow$ 点云构建 $\rightarrow$ VR 过滤 $\rightarrow$ 持久图 $\rightarrow$ Betti 数计算, 完整演示了 PH 的工作流程。

核心创新点

- 低门槛系统性教学: 面向无代数拓扑背景的读者, 从直观例子 (咖啡杯与甜甜圈) 出发逐步过渡到严格定义;
- 完整可复现的生物学案例: 提供了从蛋白质结构数据库下载坐标到计算 Betti 数的完整代码, 采用 Python 的 Ripser 和 GUDHI 库;
- 强调 PH 的互补性: 明确指出 PH 与传统 ML 方法 (监督/无监督/强化学习) 在捕获全局结构方面的互补关系。

对 SRTP 的参考价值

- 可作为 CTDA 阅读笔记的平行教材, 交叉验证理论理解的正确性;
- DNA 结构分析的 pipeline 结构与 test.py 中的范式完全一致, 可作为“跨领域应用案例”引入结题报告;
- 局限性: 仅涉及 H_0 和 H_1 , 未涉及 H_2 (空腔), 对 3D 拓扑识别目标支撑有限。

2 Paper 2: Topology-Informed Jet Tagging using Persistent Homology

来源: arXiv:2601.01450v1 [hep-ph], 2026年1月

作者: Saurav Mittal (CDAC, Pune, India)

主要内容

本文提出了一种基于持久同调的喷注标记 (jet tagging) 方法, 用于区分夸克和胶子喷注:

1. **喷注点云表示**: 将每个喷注的粒子成分表示为三维特征空间中的点云 $X = \{x_i\}_{i=1}^N \subset \mathbb{R}^3$, 特征为相对横动量 p_T^{rel} 、赝快度 η^{rot} 、方位角 ϕ^{rot} ;
2. **持久同调计算**: 采用 Vietoris-Rips 过滤计算 H_0 (连通分量) 和 H_1 (环状结构) 的持久图;
3. **持久图像 (Persistence Image)**: 将持久图转化为持久图像 (40×40 网格, 高斯核 $\sigma = 0.001$), 作为固定维度特征;
4. **CNN 分类**: 使用三个卷积块 + 批归一化 + ReLU 的 CNN 对 H_0 、 H_1 及组合持久图像进行二分类。

核心创新点

- **首次量化 H_1 在喷注分类中的独立作用**: 发现 H_0 和 H_1 的持久图像单独使用时具有相当的判别能力 (AUC 分别为 0.76 和 0.75);
- **验证了环状拓扑特征在喷注子结构中的信息价值**: 表明 H_1 编码了传统喷注标记方法未利用的物理信息;
- **消融实验设计**: 比较了 H_0 only、 H_1 only、 H_0+H_1 三种输入组合的性能差异。

对 SRTP 的参考价值

- Pipeline 与 test.py 高度同构 (点云 $\rightarrow$ VR 过滤 $\rightarrow$ PD $\rightarrow$ 向量化 $\rightarrow$ ML), 是”Top-K 寿命 + 随机森林”向”持久图像 + CNN”升级的直接参考;
- 特征空间构造思路 (用物理意义更强的特征而非原始坐标) 对 ModelNet40 处理有启发;
- 局限性: 粒子物理领域, 应用场景与 SRTP 差异较大。

3 Paper 3: Learning Significant Persistent Homology Features for 3D Shape Understanding

来源: arXiv:2602.14228v1 [cs.CV], 2026年2月

作者: Prachi Kudeshia, Jiju Poovvancheri (Saint Mary's University, Canada)

主要内容

本文针对 3D 点云形状理解, 提出了拓扑增强数据集和基于深度学习的显著拓扑特征选择方法:

- **拓扑增强数据集**: 为 ModelNet40 和 ShapeNet 构建了附带 H_1 和 H_2 持久图的数据集 (ModelNet40-PD, ShapeNet-PD), 计算耗时超过 860 小时;
- **TopoGAT 架构**: 一种基于图注意力网络 (GAT) 的三支网络, 同时学习点云的几何特征、 H_1 拓扑特征和 H_2 拓扑特征;
- **显著特征选择机制**: 通过回归头预测每个持久图的阈值, 利用 sigmoid 软掩码进行可微过滤, 结合拓扑损失函数 (Wasserstein 距离 + 持久熵 + 缩减率) 进行端到端学习;
- **下游任务验证**: 在分类 (ModelNet40) 和部件分割 (ShapeNet) 上验证, TopoGAT 选择后的显著特征比全部特征或传统统计筛选方法表现更好。

核心创新点

- 首个面向 3D 点云的拓扑增强基准数据集：解决了 PH 计算成本高、难以在训练时实时生成的问题；
- TopoGAT 可学习显著特征选择：替代了传统 Top-K 固定截断或统计置信带方法，能根据数据自适应选择最相关的拓扑特征；
- 三支路 + 分类引导的回归：分类头的预测概率指导回归头为不同类别生成特异性阈值；
- 复合拓扑损失：结合 Wasserstein 距离损失（保持分布）、持久熵损失（防止过度简化）和缩减率损失（控制保留数量），三者权重可学习。

对 SRTP 的参考价值

- 与 SRTP 研究方向（3D 点云 + PH + 深度学习 + 分类/分割）最直接相关；
- 可直接使用其预计算的拓扑增强数据集，节省大量预处理时间；
- TopoGAT 的”学习筛选显著特征”思路为第二阶段”设计自己的 pipeline”提供了参考方案。

4 Paper 4: A Persistent Homology Design Space for 3D Point Cloud Deep Learning

来源：arXiv:2604.04299v1 [cs.CV], 2026年4月

作者：Prachi Kudeshia, Jiju Poovvancheri 等 (Saint Mary's University)

主要内容

本文提出了一个统一的 3DPHDL (Persistent Homology driven learning for 3D Point Clouds) 设计空间，系统化地梳理了 PH 与 3D 深度学习结合的各类设计选择：

1. **标准 PHML Pipeline:** 复杂构造 (VR/Čech/Alpha/Cubical/Witness/Flood/SSC) → 过滤 (距离/函数/学习) → PH 计算 → 向量化 (PI/PL/Betti 曲线/PersLay) → 神经网络架构 → 预测任务；
2. **六个 PH 注入点 (IP1–IP6):**
 - IP1: PH 引导的采样与分块 (拓扑感知下采样)；
 - IP2: PH 感知的邻域图与卷积 (拓扑重要性加权边、持久感知池化)；
 - IP3: 训练动态与优化 (拓扑损失、PH 触发的更新调度)；
 - IP4: 自监督与数据增强 (PH 保持的正例 / PH 破坏的负例)；
 - IP5: 输出校准与标签空间 (预测掩码的 PH 验证、拓扑不确定性)；
 - IP6: 网络自身的隐式 PH (神经持久性、特征图 PH、持久 Laplacian 正则化)。
3. **系统实验对比:** 在 PointNet、DGCNN、Point Transformer 三个 backbone 上，系统比较了 PD、PI、PL 三种向量化方法在分类和分割任务上的效果。

核心创新点

- 首个 3DPHDL 设计空间框架：将 PH+DL 的所有设计选择系统化，超越了“PH 仅作为辅助特征”的狭隘视角；
- 六维注入点体系：将 PH 从“旁路特征”提升为“结构归纳偏置”，可渗透到数据处理、架构设计、优化训练、自监督、输出校准等各个环节；
- 全面的实验分析：比较不同复形构造的计算复杂度（图 8）、拓扑稳定性（图 9）、以及不同向量化方法的性能/开销 trade-off（表 4、表 5）。

对 SRTP 的参考价值

- 为“设计自己的 pipeline”提供了最高级别的框架性指导——完整的“菜单”供选择；
- 六个注入点为 SRTP 创新提供了多个可能方向（如 PH 引导采样、拓扑感知邻域图）；
- 实验结论可作为选择 backbone 和向量化方法的直接依据（PL 性能最佳且参数少）；
- 论文结构（问题→设计空间→系统实验→Trade-off 分析）适合用作结题报告的组织框架。

5 Paper 5: Adaptive Topological Feature via Persistent Homology: Filtration Learning for Point Clouds

来源：NeurIPS 2023

作者：Naoki Nishikawa (东京大学), Yuichi Ike (九州大学), Kenji Yamanishi (东京大学)

主要内容

本文提出了一种可学习的加权过滤框架，通过神经网络为点云中的每个点自适应地学习权重，从而获得任务相关的拓扑特征：

1. **加权过滤 (Weighted Filtration)**：对点云 $X = \{x_1, \dots, x_N\}$ ，定义权重函数 $w : X \rightarrow \mathbb{R}$ ，构造加权 Rips 过滤 $R[X, w]$ ，使不同半径的球以不同速率膨胀；
2. **等距不变网络架构**：基于距离矩阵和 DeepSets 架构设计权重函数 $f_\theta(X, x)$ ，满足对任意等距变换 T 有 $f_\theta(TX, Tx) = f_\theta(X, x)$ ；
3. **两阶段训练**：第一阶段训练 DNN 特征提取器，第二阶段固定 DNN 并联合训练拓扑特征提取器和分类器，避免联合优化不稳定；
4. **理论保证**：证明了任意连续权函数可通过两个有限维特征向量的组合逼近（Theorem 4.1）。

核心创新点

- 首次提出点云数据的可学习过滤：在此之前，过滤学习仅在图数据上实现，因点云缺乏邻接结构且需要等距不变性，面临根本性挑战；
- 等距不变性保证：利用距离矩阵而非坐标实现严格的等距不变性，使 PH 特征对旋转、平移、反射不敏感；
- 有限维逼近定理：为基于距离矩阵的架构提供了理论基础，证明其表达能力足够；

- **两阶段训练策略**：解决了 PH 特征与 DNN 特征联合优化不稳定的问题。

对 SRTP 的参考价值

- 可学习过滤是**核心创新方向**——从“固定 VR 过滤”到“自适应过滤”，学术价值大幅提升；
- 等距不变性与 SRTP 目标“处理三维物体旋转不变性”直接对应；
- 与 TopoGAT (2602) 正交：TopoGAT 关注“选择哪些特征重要”，本文关注“如何让过滤本身可学习”，两者可组合；
- 局限性：计算成本高（每次训练约 7 小时），在大数据集上扩展性有限。

6 Paper 6: Topology and Data

来源：Bulletin of the American Mathematical Society, 46(2):255–308, 2009

作者：Gunnar Carlsson (Stanford University)

主要内容

这是 TDA 领域最经典的奠基性综述之一，由 TDA 创始人 Gunnar Carlsson 撰写，阐述了拓扑学在数据分析中的方法论价值：

1. **现代数据挑战**：高维性、坐标人工性、度量不自然、噪声大、缺失多——传统方法难以应对；
2. **拓扑学的四个关键优势**：
 - 提供**定性信息**（如连通性、环结构），而非仅定量信息；
 - 对**度量选择不敏感**，适用于度量不明确的场景（如生物学）；
 - **坐标无关性**，不依赖于特定坐标系；
 - **函子性 (Functoriality)**——通过参数变化下的连续映射关系获得更丰富的信息。
3. **聚类分析**：探讨了聚类的模糊性，以及如何用函子性框架处理多参数聚类问题；
4. **持续同调**：介绍了持久同调的基本思想，强调“摘要 (summaries) 比单参数选择更有价值”；
5. **Mapper 算法**：介绍了基于 Reeb 图的 Mapper 算法。

核心创新点

- **奠定了 TDA 的哲学基础**：系统阐述了“为什么拓扑学对数据分析有用”这一核心问题；
- **引入函子性思想**：将代数拓扑中的函子性引入数据分析，为多尺度分析和多参数分析提供了理论框架；
- **开创性工作**：提出了持久同调在数据分析中的应用范式，影响深远（引用量极高）。

对 SRTP 的参考价值

- 为结题报告的**引言/背景部分**提供了思想层面的深度——“为什么 TDA 有效”；
- 作为 TDA 领域引用量最高的论文，可增强结题报告的学术规范性；
- 局限性：出版于 2009 年，未涉及深度学习等最新进展，更多是方法论层面的指导。

7 Paper 7: Extracting Insights from the Shape of Complex Data Using Topology

来源: Scientific Reports, 3:1236, 2013

作者: P. Y. Lum, G. Singh, A. Lehman, G. Carlsson 等 (Ayasdi Inc. & Stanford)

主要内容

本文展示了基于 Mapper 算法的 TDA 方法在三个真实世界数据集上的应用:

1. **方法概述:** 基于广义 Reeb 图的拓扑数据分析方法, 输入为距离度量、过滤函数 (filter function) 和分辨率参数, 输出为网络状表示;
2. **乳腺癌基因表达数据:** 分析 NKI 和 GSE2034 两个数据集, 发现了传统方法 (如 PCA、聚类分析) 未能识别的患者亚群;
3. **美国众议院投票数据:** 分析 20 年间的投票行为, 揭示了党派凝聚力和分裂模式的演变;
4. **NBA 球员数据:** 根据球员表现数据识别出 13 种不同的打球风格;
5. **多网络对应分析:** 创新性地实现了跨数据集的网络形状比较。

核心创新点

- **探索性数据分析范式:** 提出了一种无需先验假设的数据探索方法, 不同于传统假设驱动的分析方法;
- **形状即信息:** 强调“环”和“光晕/分支”等拓扑模式如何揭示数据中的隐藏子群;
- **跨网络比较:** 提出了在多个网络间建立对应关系的方法, 用于跨时间、跨数据集或跨尺度的比较分析;
- **工业级应用验证:** 三个领域 (医学、政治、体育) 的案例验证了 TDA 的实际应用价值。

对 SRTP 的参考价值

- 可作为结题报告“应用前景”章节的典型示例;
- 了解 Mapper 思路有助于在第三阶段“高维抽象数据”中思考是否需要以 Mapper 补充 PH;
- 局限性: 使用 Mapper 而非 PH, 与 SRTP 核心技术路线 (PH+ML) 不直接相关。

总结：各论文在 SRTP 中的定位

论文	类型	SRTP 定位
Paper 1 (2505)	教学入门	理论补充 + 跨领域应用案例
Paper 2 (2601)	应用研究	Pipeline 升级参考 (Top-K → PI + CNN)
Paper 3 (2602)	方法研究	最直接相关——TopoGAT + 拓扑增强数据集
Paper 4 (2604)	综述/框架	最高级别框架指导——设计空间 + 六个注入点
Paper 5 (NeurIPS)	方法创新	核心创新方向——可学习过滤
Paper 6 (Carlsson)	奠基综述	思想基础——结题报告引言引用
Paper 7 (srep01236)	应用案例	应用前景展示